Configuración Técnica
Documento de implementación

1. Base y configuración experimental

Base técnica. Se incorporó el código fuente de MALLM al repositorio del proyecto y se instaló en modo editable con Python 3.12. La configuración experimental quedó fijada en mallm/utils/config.py: discussion_paradigm="memory"; response_generator="critical"; decision_protocol="approval_voting"; num_agents=8; agent_generator="predefined"; all_agents_generate_first_draft=True; visible_turns_in_memory=10; max_turns=10; max_tokens=24000; use_chain_of_thought=False; skos_enabled=True; skos_ontology_dir="../..".

2. Perfiles de agentes predefinidos

Modificación propia. Se creó mallm/models/personas/PredefinedPersonaGenerator.py y se registró "predefined" en mallm/utils/dicts.py. Los ocho agentes se cargan desde metadata["personas"] con campos role y description; no son personas generadas por el LLM. Los perfiles sustantivos definitivos quedan fuera del código y son suministrados por el investigador.

3. Ronda 1: First Draft → SKOS → Second Draft

Primera salida. Con all_agents_generate_first_draft=True, cada agente produce independientemente un First Draft a partir de Task/Context + Input + role/persona, sin observar los drafts simultáneos de los demás. El Context se incorpora previamente a task_instruction.

Intervención SKOS. Se creó mallm/models/skos/SKOSProcessor.py (rdflib) y se integró al Coordinator/Agent. El procesador carga exactamente 11 ontologías TTL externas: racionalidad, valores, social, politica, institucional, tecnologica, ambiental, economica, accountability, engagement y compliance. El First Draft se conserva; SKOS aporta estructura semántica —no matching de palabras clave— y construye un prompt ontológicamente enriquecido. Ese prompt vuelve al mismo agente/LLM, junto con su identidad, para generar una nueva posición: el Second Draft. Se preservan separadamente First Draft, prompt/interpretación SKOS y Second Draft en Memory.additional_args["skos"]. El Second Draft pasa a ser la posición activa para la deliberación.

4. Deliberación crítica e información simétrica

Modificación metodológica central. Se modificaron mallm/agents/agent.py y mallm/discussion_paradigms/paradigm.py para que cada agente reciba memoria completa de rondas anteriores pero no mensajes producidos durante su misma ronda (include_this_turn=False). Con Approval Voting y turn>=2 se fuerza current_draft=None: no existe una solución corriente privilegiada ni la salida del último agente actúa como punto de partida. Por ello, todos los agentes de una misma ronda reciben el mismo estado informacional previo.

Secuencia. Ronda 2: cada agente observa simétricamente los ocho Second Drafts de ronda 1 y produce una nueva posición mediante CriticalResponseGenerator. Ronda 3: cada agente observa todas las posiciones terminadas de ronda 2, pero ninguna salida contemporánea de ronda 3; vuelve a sintetizar críticamente su posición. El historial distingue los mensajes propios (assistant) de los ajenos (user + persona), permitiendo continuidad de la propia posición y consideración de las demás sin dependencia del orden de ejecución.

5. Decisión: Approval Voting desde ronda 2 ANONIMO

Configuración final. Se sustituyó hybrid_consensus por el protocolo nativo ApprovalVoting (mallm/decision_protocols/approval_voting.py), con vote_turn=2. La decisión se evalúa únicamente después de que todos los agentes completan la ronda. En ronda 2, MALLM genera las respuestas finales de los panelistas a partir de sus posiciones de esa ronda y ejecuta la votación de aprobación: cada panelista puede aprobar una o más propuestas. Si existe una única propuesta con el mayor número de aprobaciones, agreed=True y esa propuesta gana; si hay empate en el máximo, agreed=False y la deliberación continúa hasta max_turns.

6. Trazabilidad técnica

Archivos propios/modificados principales: PredefinedPersonaGenerator.py; SKOSProcessor.py; agents/agent.py; coordinator.py; discussion_paradigms/paradigm.py; utils/config.py; utils/dicts.py; pyproject.toml/poetry.lock (rdflib). **Commits relevantes:** cec1e26 (perfiles predefinidos), 2a89ba1 (integración SKOS), 2588d28 (memoria sincrónica/configuración experimental), f9740a4 (Approval Voting + deliberación simétrica).